

# 라벨을 몇 개 더 확인해야 하는가? 선택적으로 관측된 라벨에서의 미니맥스 평가

이초록 | KAIST

모델이 잘 맞는 것처럼 보여도, 어려운 사례의 정답만 아직 확인되지 않았을 수 있습니다. 추가로 정답을 확인한다면 몇 개가 필요할까요? 이 논문은 위험 증가를 발견하는 데 필요한 감사 규모를 최악의 상황까지 고려해 분석합니다.

## 무엇을 묻는가

이미 예측과 실제 결과가 존재하는 고정된 사례 집단을 생각합니다. 라벨을 보류하는 과정은 결과를 알고 있을 수 있으므로, 관측된 사례만으로 계산한 정확도는 편향될 수 있습니다. 평가자는 미확인 사례를 비공개 무작위 방식으로 골라 정답을 확인합니다. 목표는 허용 가능한 위험에 관한 가설이 깨졌는지 검사하는 것입니다. 검정력은 정해 둔 더 높은 위험을 발견할 확률이고, 오경보율은 허용 가능한 위험에서도 잘못 경고할 확률입니다.

## 어떻게 접근하는가

논문은 라벨 확인 횟수가 고정된 상태에서 사례 수가 커질 때 가능한 최악 상황의 최대 검정력을 구합니다. 기존 관측 전체를 활용하고 다음 확인 대상을 적응적으로 고르는 방법까지 비교 대상으로 포함합니다. 정답이 정확하다면 단순한 균등 무작위 확인으로도 이 점근적 한계에 도달합니다. 또한 오류 개수의 꼬리확률을 제한하는 가정, 누적 조건부 위험을 제한하는 가정, 평균 위험만 제한하는 가정을 구분합니다.

## 핵심 결과

예측 1,000개 중 500개의 라벨이 미확인이고, 허용 위험 10%와 대안 위험 20%를 구분하며 오경보율을 5% 이하로 제한하는 예에서, 검정력 95%를 위한 최소 확인 횟수는 정확히 57회입니다. 이는 정답 라벨과 오류 개수의 꼬리확률 가정 아래의 유한 표본 결과입니다. 별도로 같은 위험과 미확인 비율에서 95%의 점근적 검정력을 얻는 수치 계산은, 10% 대칭 잡음의 구조를 정확히 알면 94회, 조건부 신뢰도 범위만 알면 367회를 요구합니다. 이 두 수치는 유한 표본 보장이 아닙니다.

## 왜 조건을 함께 봐야 하는가

57회 규칙은 위험 20%를 발견하도록 설계되어, 실제 위험이 12%이면 검정력이 약 1.15%로 낮아집니다. 두 규칙을 무작위로 섞으면 20%에서 95% 이상을 유지하면서 12%에서 8.66%로 개선하지만 여전히 낮습니다. 예측 1,000개의 정답을 전부 알아도 10%와 12%를 구분하는 최적 검정력은 65.32%입니다. 95%에 도달하려면 완전한 라벨이 있는 사례가 최소 2,645개 필요합니다. 평균 위험만 가정하는 경우에는 모든 라벨을 알아도 낮은 검정력 한계가 남을 수 있습니다.

## 어떻게 활용하는가

감사 전에 허용 위험, 발견하려는 위험 증가, 사례 수, 미확인 개수의 상한, 라벨 신뢰도 가정을 정해야 합니다. 조건이 맞는 유한 표본 보장을 사용하고, 계획한 위험과 다른 상황의 성능도 확인해야 합니다. 논문은 고정된 관측 기록, 비공개 표본추출, 이미 존재하여 확인 가능한 결과, 한 번의 판정 시점을 가정합니다. 실제 운영에서 이 조건들이 성립하는지 검증한 연구는 아니며, 경고가 없다는 이유만으로 위험이 허용 수준이라고 입증할 수 없습니다.

### 핵심 메시지

필요한 것은 라벨 수만이 아닙니다. 라벨의 품질에 관해 아는 정보와 전체 사례 수도 감사의 검정력을 함께 결정합니다.