

분포 변화에서 컨포멀 예측은 왜 실패하는가: COVID-19 사례 연구

이초록 | KAIST

세상이 바뀌면 모델은 확신을 갖고 틀릴 수 있습니다. 가능한 정답들을 모아 주는 컨포멀 예측도 그 목록에서 실제 정답을 놓칠 수 있습니다. 이 논문은 미래 데이터를 보기 전에 모델의 취약성을 짐작할 신호가 있는지 묻습니다.

어떤 문제인가

커버리지는 예측 집합에 실제 정답이 포함되는 비율입니다. 일반적인 컨포멀 예측의 보장은 보정 데이터와 미래 데이터의 교환가능성에 의존합니다. 이 연구는 같은 COVID 시기 구간을 거친 공급망 예측 과제들이 왜 서로 다른 커버리지 손실을 보이는지 살펴봅니다. 주된 대상은 90% 커버리지를 목표로 APS를 적용한 그래디언트 부스팅 다중분류 모델입니다.

어떻게 접근했나

핵심 지표는 최상위 SHAP 집중도입니다. 검증 데이터에서 계산한 피처별 절대 SHAP 값의 평균 중 가장 큰 값을 전체 합으로 나눕니다. 한 피처에 설명상 중요도가 물린 모델은 그 피처에 불리한 변화가 생길 때 취약할 수 있다는 가설입니다. 확률 공간의 가법적 모형을 가정한 이론이 이 방향을 설명하지만, 실제 TreeSHAP 집중도의 미래 성능을 보장하는 정리는 아닙니다.

무엇을 관찰했나

SALT 공급망 8개 과제의 커버리지 손실은 0.1~77.1%p로 크게 달랐습니다. 과제별 50개 시드는 독립적인 모델 학습 실험이며, 50개 모델의 예측을 합친 앙상블은 아닙니다. 9개 도메인, 16개 다중분류 과제를 합친 분석에서 집중도와 커버리지 손실의 스피어만 상관계수는 0.853이었습니다. 보고된 p값은 0.001 미만, 부트스트랩 95% 구간은 [0.50, 0.96]입니다. 이 분석에는 기존 SALT 8개와 외부 8개가 포함되며, 외부 과제 중 4개는 실제 변화가 문서화된 설정, 4개는 변화가 없는 대조 설정입니다.

어디까지 믿을 수 있나

탐색적으로 제시한 집중도 40% 기준에는 예외가 있습니다. sales-office는 기준을 넘지만 거의 실패하지 않았고, KDDCup99는 기준보다 낮지만 시드에 따라 손실이 커졌습니다. 보조 피처의 보호 효과를 점검하는 규칙은 한 사례에서 나왔습니다. 랜덤 포레스트와 MLP에서는 관계가 더 약하며, 집중도가 낮아도 신경망은 크게 실패할 수 있습니다. 전체 상관분석은 기준을 만든 기존 과제도 포함하므로 완전히 새로운 검증으로 해석하면 안 됩니다.

왜 유용한가

이 논문은 데이터가 변했는지만 확인하지 말고, 그 변화가 모델이 의존하는 피처를 건드리는지도 살펴보고 제안합니다. 집중도는 배포 전 점검과 모니터링의 우선순위를 정하는 신호가 될 수 있습니다. 향후에는 규칙을 미리 고정한 전향적 검증이 필요합니다. 커버리지를 되찾더라도 예측 집합이 너무 커지면 실용성이 떨어지므로, 정답 포함률과 집합의 유용성을 함께 평가해야 합니다.

핵심 메시지

높은 집중도는 취약성을 점검하라는 경고 신호입니다. 특히 부스팅 다중분류 모델에서 유용할 수 있지만, 실패나 안전을 확정하는 기준은 아닙니다.